

PEC 2 Inferencia Estadística:

Raúl Pérez Prats

1-A)

El estudio consiste en medir la efectividad de 3 tratamientos sobre 500 individuos, supuestamente distribuidos de forma equitativa entre las 3 clases.

Definimos las hipótesis:

F_{zi} = frecuencia de cultivo negativo

$H_0: 1 - F_{zi} = 1$ El tratamiento no es efectivo

$F_{zi} = 0$

$H_1: 1 - F_{zi} < 1$ El tratamiento es efectivo

$F_{zi} > 0$

Generamos una tabla de contingencia que contenga la proporción de positivos y negativos en cada tratamiento donde n_i es la frecuencia de positivos en gonorrea:

Tratamiento:	1	2	3
Positivo	n_1	n_2	n_3
Negativo	$1-n_1$	$1-n_2$	$1-n_3$

n = Frecuencia de positivos

Para determinar si cada tratamiento es efectivo realizamos un test chi-cuadrado con 3 grados de libertad y calculamos el p-valor. Si éste es menor a 0.05 rechazamos la hipótesis nula y si es mayor la aceptaremos.

1-B)

Se quiere observar las diferencias en los niveles de ácido úrico en 250 individuos antes y después de cierto tratamiento.

Definimos las hipótesis:

N_0 = nivel medio inicial

N_f = nivel medio final

$H_0: n_0 = n_f$ Los niveles iniciales y finales son iguales, no es efectivo el tratamiento

$H_1: n_0 > n_f$ Los niveles iniciales son mayores a los finales, es efectivo el tratamiento

Para esto podemos comparar las medias de los niveles de ácido úrico de los individuos antes y después del tratamiento y determinar si son significativamente diferentes.

Para comprobar nuestras hipótesis (suponiendo que la muestra sigue una distribución normal) podemos emplear un T test apareado, debido a que se trata de un experimento realizado en los mismos individuos en 2 momentos distintos: antes y después de un tratamiento.

Para aplicar este test debemos confirmar la normalidad de las distribuciones de los niveles de ácido úrico de los individuos de la muestra. Para ello se aplica un test de Shapiro Wilk.

En caso de que el test Shapiro Wilk indique que la muestra no sigue una distribución normal deberemos aplicar un test no paramétrico de Wilcoxon.

Aceptaremos o rechazaremos la hipótesis nula a partir del p-valor obtenido a partir del T test apareado. Si $p\text{-valor} > 0.05$ aceptamos H_0 , si $p\text{-valor} < 0.005$ rechazamos H_0 y por lo tanto el tratamiento es efectivo.

1-C)

Tenemos 857 pacientes divididos en 3 grupos a los que se les aplica un tratamiento para reducir la PP de 8 semanas de duración.

Planteamos las hipótesis:

m_0 = media inicial

m_f = media final

$H_0: m_0 = m_f$ Las medias de PP antes y después del tratamiento son iguales, el tratamiento no disminuye la PP

$H_1: m_0 > m_f$ Las medias de PP son superiores antes del tratamiento, es efectivo el tratamiento

En este estudio se han dividido a los participantes en 3 grupos a modo de control negativo para demostrar que las diferencias entre individuos no influyen en el tratamiento y que los efectos de éste se deben 100% a su efectividad y que no dependen del individuo particular.

Para comparar las medias de los 3 grupos antes y después se realiza un ANOVA de 2 factores independientes de medidas repetidas: Tiempo (2 niveles) y Grupo (3 niveles)

Asumiremos normalidad y error homogéneo. Cuando el error es homogéneo entre todos los grupos se demuestra que las diferencias de las medias antes y después del tratamiento vienen determinadas solamente por el fármaco, ya que tenemos la misma varianza en los 3 grupos.

En caso de detectar que nuestra distribución muestral no sigue una normal mediante el test Shapiro Wilk, realizaríamos un test no paramétrico de Kruskal Wallis.

1-D)

En el experimento se intenta demostrar una disminución del % de suciedad bucal mediante la aplicación de una intervención.

Planteamos hipótesis:

F_{zi} = frecuencia de individuos que reducen % de suciedad bucal

$H_0: 1 - F_{zi} = 1$ El tratamiento no es efectivo

$F_{zi} = 0$

$H_1: 1 - F_{zi} < 1$ El tratamiento es efectivo

$F_{zi} > 0$

Hacemos una tabla de contingencia con los individuos que reducen su % de suciedad bucal:

Tratamiento:	Si	No
Antes	A1	B1
Después	A2	B2

A = Frecuencia tratados

B = Frecuencia no tratados

Aplicamos un test de McNemar debido a que se trata de individuos relacionados, ya que se trata de los mismos individuos pasado 6 meses después del tratamiento.

Aceptamos o rechazamos la hipótesis nula a partir del p-valor. Si $p\text{-valor} > 0.05$ aceptamos H_0 , si $p\text{-valor} < 0.005$ rechazamos H_0 y por lo tanto el tratamiento es efectivo.

1-E)

Para determinar si los niveles de vitamina D en sangre en individuos mayores a 70 años son aumentan en presencia de fractura de cadera, debemos comparar el promedio de los niveles de vitamina D en el grupo de 56 individuos con fractura de cadera con el promedio de los 39 individuos sin fractura.

Planteamos hipótesis:

m_1 = media niveles vitamina D con presencia de fractura

m_2 = media niveles vitamina D sin fractura

$H_0: m_1 = m_2$ Las medias de niveles de vitamina D son iguales con y sin fractura, la presencia de fractura no influye a los niveles de vitamina D en sangre

$H_1: m_1 > m_2$ Las medias de niveles de vitamina D son superiores en presencia de fractura, la presencia de fractura si influye en los niveles de vitamina D en sangre

Para evaluar que hipótesis aceptamos realizaremos un T-test para varianzas iguales en caso de disponer de una distribución normal y de varianzas homogéneas en nuestras muestras de niveles de vitamina D en sangre.

En el caso de no disponer de varianzas homogéneas utilizaríamos un T-test para varianzas separadas.

Finalmente, en el caso de no disponer de unas muestras con distribución normal utilizaríamos un test no paramétrico U de Mann-Whitney.

Aceptamos o rechazamos la hipótesis nula a partir del p-valor. Si $p\text{-valor} > 0.05$ aceptamos H_0 , si $p\text{-valor} < 0.005$ rechazamos H_0 y por lo tanto la presencia de fractura afecta a los niveles de vitamina D en sangre.

2-A)

```

```{r}

shapiro_test_demora <- shapiro.test(demora300$demora)

shapiro_test_demora

shapiro_test_logdemora <- shapiro.test(logdemora)

shapiro_test_logdemora

...

 Shapiro-wilk normality test

data: demora300$demora
W = 0.54628, p-value < 2.2e-16

 Shapiro-wilk normality test

data: logdemora
W = 0.9722, p-value = 1.49e-05

```

En ambos casos el p-valor es inferior a 0.05, por lo tanto ninguna de estas dos distribuciones sigue una normal.

```



```{r}

qqnorm(logdemora)
qqline(logdemora, col = 2)

qqnorm(demora300$demora)
qqline(demora300$demora, col = 2)

...

```




Tal y como podemos observar en ambos gráficos ninguna de las dos distribuciones, demora y logdemora, se superpone de forma adecuada los valores de los cuantiles sobre la recta modelo de la distribución normal, por lo tanto, tal y como nos ha indicado el test Shapiro Wilk, estas dos distribuciones no siguen una normal.

No obstante, cabe destacar que el QQplot Logdemora muestra una mejora en cuanto a la superposición de los valores de los cuantiles respecto a la recta modelo normal, cosa que

indica de forma intuitiva que la transformación logarítmica ha 'normalizado' en cierta medida, aunque no de forma suficiente según los resultados del Shapiro Wilk, nuestra distribución.

Si representamos las distribuciones demora (izquierda) y logdemora (derecha) mediante histogramas podemos ver que efectivamente la distribución de demora no sigue una distribución normal, sino que se asemeja más a una distribución exponencial negativa, en cambio, tal y como nos ha indicado el QQplot de Logdemora, estos datos transformados se ajustan mejor a una distribución normal.



2-B)

Para evaluar la asociación de la demora y la intensidad del dolor tenemos que ser capaces de establecer si hay diferencias significativas entre la demora en los 3 grupos de niveles de dolor.

Planteamiento Hipótesis:

$H_0: m_1 = m_2 = m_3$ Las medias de demora son iguales independientemente del grado de dolor

$H_1: m_1 \neq m_2 \neq m_3$ Las medias son diferentes dependiendo del grado de dolor

Para hacer este análisis recurriremos a un test no paramétrico Kruskal Wallis, ya que la distribución de nuestros datos no sigue una normal:

```
```{r}
```

```
kruskal_test_result <- kruskal.test(demora ~ dolor, data=demora300)
```

```
kruskal_test_result
```

```
```
```

```
kruskal-wallis rank sum test
```

```
data: demora by dolor
```

```
Kruskal-Wallis chi-squared = 10.529, df = 2, p-value = 0.005171
```

Como que $p\text{-valor} < 0.05$ rechazamos H_0 y por lo tanto si que hay diferencias entre los niveles de dolor.

Para ver entre qué grupos se hallan las diferencias aplicamos un test de comparaciones múltiples de Dunn con la corrección para el p-valor de Bonferroni:

```
```{R}
```

```
posthoc_dunn <- dunn.test(demora300$demora, demora300$dolor, method = "bonferroni",)
```


```
print(posthoc_dunn)
```

```
...
```

Comparison of x by group (Bonferroni)			
Col	Mean-		
Row	Mean	Intenso	Ligero
Ligero		-1.731117 0.1251	
Moderado		-3.119992 0.0027*	-0.099686 1.0000

El test nos indica que existen diferencias significativas en la demora entre los grupos de dolor moderado e intenso. Por lo tanto, aquellos individuos que presentan un nivel de dolor intenso, si que presentan tiempos de demora distintos al acudir al hospital que aquellos individuos con un dolor moderado. Podemos intuir mediante el gráfico que los tiempos de demora de los individuos con un dolor intenso son menores.

**Boxplot de Demora según intensidad de dolor**



## 2-C)

Para comparar la relación entre la demora y la aparición nocturna o diurna del dolor debemos utilizar un test que permita establecer si existen diferencias significativas entre el promedio de la demora de estos dos grupos. Como no disponemos de una muestra con distribución normal aplicaremos un test no paramétrico U de Mann-Whitney.

Planteamos hipótesis:

H0:  $m_1 = m_2$  Media demora diurna y nocturna son iguales

H1:  $m_1 \neq m_2$  Media demora nocturna y diurna son diferentes

```
```{r}
```

```
#U mann whitney
```

```
mann_whitney_test_result <- wilcox.test(demora ~ noche, data = demora300)
```

```
mann_whitney_test_result
```

```
```
```

```
wilcoxon rank sum test with continuity correction
```


```
data: demora by noche
```

```
W = 6686, p-value = 0.009651
```

```
alternative hypothesis: true location shift is not equal to 0
```

Efectivamente el p-valor es inferior a 0.05 y por lo tanto existen diferencias entre el tiempo de demora diurno y nocturno.

### Boxplot demora Noche



Tal y como podemos ver en los boxplot comparativos, la demora durante los infartos diurnos es mucho menor que en los nocturnos.

### 2-D)

En el apartado 2-A) hemos comentado que la transformación logarítmica de las muestras reajusta en gran medida nuestra muestra de demora a una distribución normal, aunque el Shapiro Wilk test sigue indicando que la distribución de la logdemora no se ajusta a una normal, teniendo en cuenta que nuestra muestra de 300 individuos es superior a 30 individuos y que se ajusta de forma suficiente a la línea modelo del QQplot, podemos repetir el análisis suponiendo normalidad.

### Repetición 2B)

Comprobamos homocedasticidad para determinar si podemos aplicar ANOVA con un test de Levene:

```
```{r}
```

```
library(car)
```

```
levene_test_result <- leveneTest(logdemora~demora300$dolor)
```

```
---
```

```
Levene's Test for Homogeneity of Variance (center = median)
```

```
      Df F value    Pr(>F)
group  2  5.2578 0.005702 **
      297
```

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como el p-valor es inferior a 0.05 nuestros datos no tienen homogeneidad de varianzas i por lo tanto debemos seguir aplicando el test de Kruskal Wallis como en el análisis anterior:

```
```{r}
```

```
Realizamos el test de Kruskal-Wallis
```

```
kruskal_test_result <- kruskal.test(logdemora ~ demora300$dolor)
```

```
kruskal_test_result
```

```
Realizamos la prueba post hoc de Dunn
```

```
posthoc_dunn <- dunn.test(logdemora, demora300$dolor, method = "bonferroni",)
```

```
print(posthoc_dunn)
```

```

```

```
Kruskal-wallis rank sum test
```

```
data: logdemora by demora300$dolor
```

```
Kruskal-wallis chi-squared = 10.529, df = 2, p-value = 0.005171
```

```
 Kruskal-wallis rank sum test
```

```
data: logdemora and group
```

```
Kruskal-wallis chi-squared = 10.5292, df = 2, p-value = 0.01
```


Comparison of logdemora by group  
(Bonferroni)

Col Mean- Row Mean	Intenso	Ligero
Ligero	-1.731117 0.1251	
Moderado	-3.119992 0.0027*	-0.099686 1.0000

Este análisis con logdemora nos da exactamente el mismo resultado que en el análisis anterior, que ya hemos comentado.



### Boxplot de logdemora según intensidad de dolor



#### Repetición 2C)

Por los motivos mencionados anteriormente, suponemos una distribución normal en nuestra variable demora.

Comprobamos la homogeneidad de las varianzas mediante un F-Test:

```
```{r}
```

```
levене_test_result <- leveneTest(logdemora~demora300$noche)
```

```
levене_test_result
```

```
```
```

Levene's Test for Homogeneity of Variance (center = median)

|       | Df  | F value | Pr(>F)        |
|-------|-----|---------|---------------|
| group | 1   | 11.23   | 0.0009083 *** |
|       | 298 |         |               |

```

```

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1  
F test to compare two variances

El p-valor es 0.0009, menor a 0.05, por lo tanto no podemos afirmar homogeneidad en las varianzas.

Debido a este motivo usamos un T-test para varianzas separadas:

```
```{r}
```

```
# Realizar t-test para varianzas separadas
```

```
t_test_result <- t.test(logdemora~demora300$noche, var.equal = FALSE)
```

```
print(t_test_result)
```

```
```
```

Welch Two Sample t-test


data: logdemora by demora300\$noche

```



t = -2.9327, df = 103.73, p-value = 0.004136
alternative hypothesis: true difference in means between group Dia and
group Noche is not equal to 0
95 percent confidence interval:
-0.9475107 -0.1830351
sample estimates:
mean in group Dia mean in group Noche
4.792991 5.358264

```

El p-valor es de 0.0041 y por lo tanto si que podemos afirmar que hay diferencias significativas en la demora al llegar al hospital entre aquellos individuos que sufren un infarto por el día o por la noche.



Respecto a la pregunta planteada en el 2-B) ambos métodos dan el mismo resultado en cuanto a la significancia estadística, ya que en los dos debemos aplicar un test de Kruskal Wallis, esto es debido a que aunque suponemos normalidad en el segundo análisis con los datos logdemora, estos no presentan homogeneidad en las varianzas. Por lo tanto, a mismos datos con los mismos grupos, aunque estén transformados, si aplicamos el mismo test no paramétrico no es de extrañar que lleguemos a conclusiones parecidas. Respecto a los boxplots si que es cierto que la distribución logdemora presenta una distribución más propia a la normal y muchos menos outliers.



Los histogramas de demora (izquierda) y logdemora (derecha) muestran intuitivamente la distribución que sigue la variable demora sin y con la transformación logarítmica respectivamente. Como hemos apuntado anteriormente la distribución logdemora se asemeja en mayor medida a una distribución normal, en cambio la distribución de demora encaja más con una exponencial negativa, por lo tanto presenta muchos más outliers, tal y como nos muestran los boxplots.

Es por esto que en la pregunta planteada en el 2-C) hemos usado un test no paramétrico U de Mann-Whitney con los datos demora, ya que no siguen una distribución normal, pero en cambio hemos usado un T-test para varianzas separadas en los datos logdemora. Ambos test han demostrado que hay una diferencia significativa en la demora al llegar a un hospital en caso de infarto dependiendo de si este evento ocurre durante el día o durante la noche, y en ambos casos hemos comprobado visualmente mediante un boxplot que normalmente el tiempo de demora es menor durante el día.

## 2-E)

Para comprobar si existen diferencias significativas entre la intensidad del dolor dependiendo de si su aparición sucede por el día o por la noche podemos construir una tabla de contingencia con las frecuencias correspondientes y analizar si hay diferencias significativas entre éstas mediante un test de la Chi-cuadrado.

Planteamos las hipótesis:

F = frecuencia

|                 |                                                                                                                     |
|-----------------|---------------------------------------------------------------------------------------------------------------------|
| H0: Fnoche=Fdia | No existen diferencias significativas entre la intensidad de dolor según si aparece de día o de noche               |
| H1:Fnoche>Fdia  | Existen diferencias significativas entre la intensidad del dolor según si aparece durante el día o durante la noche |

Generamos la tabla de contingencia y aplicamos el test de la chi-cuadrado:

```
```{r}
```

```
tabla_contingencia <- table(demora300$dolor, demora300$noche)
```

```
tabla_contingencia
```

```
resultado_chi_cuadrado <- chisq.test(tabla_contingencia)
```

```
resultado_chi_cuadrado
```

```
```
```

```

 Dia Noche
Intenso 105 37
Ligero 20 8
Moderado 101 29

```

```
Pearson's Chi-squared test
```

```
data: tabla_contingencia
X-squared = 0.76663, df = 2, p-value = 0.6816
```

El p-valor es de 0.6818 que es superior a 0.05, por lo tanto no podemos rechazar la hipótesis nula y, consecuentemente no podemos afirmar la existencia de diferencias significativas en la intensidad del dolor según si aparece de día o de noche y podemos concluir que esta variable no está relacionada con la intensidad del dolor.

**3-A)**

Generamos distribución de medias a partir de una muestra aleatoria de demora

```
``{r}

muestra <- sample(demora300$demora, 25, replace = TRUE)

bootstrap <- function(data, B = 1000, alpha = 0.05) {
 n <- length(data)

 bootstrap_samples <- matrix(sample(data, n * B, replace = TRUE), ncol = B)

 # Calcular la media para cada muestra bootstrap
 means <- colMeans(bootstrap_samples)

 return (means)
}


sample_means <- bootstrap(muestra)

hist(sample_means)

``
```

Podemos observar que nuestro muestreo por Bootstrapping genera una distribución aparentemente normal a partir de 1000 medias muestrales de muestras de 25 individuos.

**Histogram of bootstrapped sample means**



**Calculamos intervalos de confianza a partir de esta distribución:**

```
``{r}

muestra <- sample(demora300$demora, 25, replace = TRUE)

Función para obtener el intervalo de confianza mediante bootstrap
bootstrap_ci <- function(data, B = 1000, alpha = 0.05) {
```

```

n <- length(data)

bootstrap_samples <- matrix(sample(data, n * B, replace = TRUE), ncol = B)

Calcular la media para cada muestra bootstrap
means <- colMeans(bootstrap_samples)

Calcular el percentil alpha/2 y 1 - alpha/2
lower_bound <- quantile(means, alpha / 2)
upper_bound <- quantile(means, 1 - alpha / 2)

Retornar el intervalo de confianza
return(c(lower_bound, upper_bound))
}

Calculamos el intervalo de confianza mediante bootstrap
intervalo_confianza_bootstrap <- bootstrap_ci(muestra)
intervalo_confianza_bootstrap

```

```

 2.5% 97.5%
137.187 432.056

```

El intervalo de confianza del 95% de la media calculado mediante Bootstrap se encuentra entre 137.18 y 432 minutos de tiempo de demora.

#### **Calculamos intervalos de confianza sin bootstrapping:**

```

```{r}

datos <- demora300$demora

media_muestral <- mean(datos)

desviacion_estandar_muestral <- sd(datos)

# Tamaño de la muestra
n <- length(datos)

# Nivel de confianza del 95%
nivel_confianza <- 0.95

# Calculamos el valor crítico de la distribución t
t_critico <- qt((1 + nivel_confianza) / 2, df = n - 1)

# Calculamos el intervalo de confianza
intervalo_confianza <- c(
  media_muestral - t_critico * (desviacion_estandar_muestral / sqrt(n)),

```

```

media_muestral + t_critico * (desviacion_estandar_muestral / sqrt(n))
)
intervalo_confianza
'''
278.8061 419.7272

```

El intervalo de confianza del 95% de la media calculado de forma normal se encuentra entre 278.8 y 419.7 minutos de tiempo de demora.

El intervalo calculado mediante Bootstrap tiene un rango mayor al intervalo calculado sin Bootstrap, esto puede ser debido a que el resampling con Bootstrap añade variabilidad a las muestras, de tal forma que crea una distribución más representativa de nuestra población real. El intervalo de confianza calculado sin Bootstrap, al tener un tamaño muestral pequeño puede presentar sesgos específicos de esa muestra que nos den un intervalo de confianza de un rango menor al que se estima mediante Bootstrap.

El bootstrapping es una técnica de remuestreo muy versátil y flexible que permite estimar la distribución de un estadístico en un amplio rango de situaciones. Esta técnica es muy conveniente ya que nos permite estimar estadísticos como el promedio, la mediana, el intervalo de confianza (en este caso)... a partir de una sola muestra, mientras que sin emplear bootstrapping deberíamos de muestrear 1000 muestras de 25 individuos para llegar a las mismas conclusiones. Además nos permite adaptarnos a diversas situaciones debido a que no nos restringe el número de muestras muestreadas y nos permite obtener una aproximación de la distribución de cualquier estadístico sin depender de distribuciones teóricas específicas.